NLP 6기 공통 프로젝트 · 개체명 인식

금융 기사에서 기관·금액·지표를 글자 위치까지 정확히 찾아내기

미래에셋증권 금융기관은 3분기 날짜 영업이익 지표이 2,450억원 금액으로 전년 날짜 대비 12.5% 비율 증가했다.

2팀 김병석 김현호 박규태 진태현 최세진

2026년 10월

문제 정의

문장에서 금융 정보를 ‘정확한 글자 범위’로 뽑아야 한다

미래에셋증권은 3분기 영업이익이 2,450억원으로 전년 대비 12.5% 증가했다.

출력 = (시작 글자, 끝 글자, 태그). ‘2,450억원으로’가 아니라 ‘2,450억원’까지만 맞아야 정답

왜 필요한가

공시와 뉴스를 모니터링하거나, 금융 검색·RAG에서 문서에 기관·금액·지표 같은 메타데이터를 붙일 때 쓴다.

왜 어려운가

한국어는 단어 뒤에 조사가 붙어 있어 띄어쓰기로 자를 수 없고, 금융에서는 숫자 한 글자만 틀려도 뜻이 바뀐다.

LLM만으로는 안 되나

문장마다 API를 호출하면 처리하는 양만큼 비용이 계속 든다(Claude Opus 100문장 약 0.28달러). 속도도 느려서 Opus는 100문장에 217초(문장당 약 2.2초)가 걸렸지만, 우리 모델은 1만 문장을 약 11초에 처리했다. 우리 실험에서는 200억 파라미터 생성형 모델(test_2000 F1 0.918)도 3억 파라미터 인코더+CRF(0.924)보다 낮았다.

전체 흐름

일반 뉴스 NER에서 출발해, 데이터 분석으로 방향을 바꿨다

1단계

일반 뉴스 NER

AI Hub 웹 말뭉치, 원본 7태그
학습 30만 → 120만 문장

0.733 → 0.777

test F1

→

전환점

EDA

점수가 막힌 원인은 모델이 아니라 **라벨 일관성**,
그리고 우리가 정작 필요로 하는 **금액·비율·날짜·지표 라벨이 없음**

→

2단계

금융 NER

금융 8태그, Claude 라벨 30만 문장
후보 모델 14개 비교 (13번은 다른 분할)

0.930

최고 test F1 (앙상블 + 후처리 · 단일 모델 0.929)
+ 데모: 네이버 기사 실시간 표시

라벨 일관성 문제의 예 (원본 test 데이터)

17일 국회 기관 국방위원회의 … 국정감사에서

20대 국회 라벨 없음 국토교통위원회가 24일 첫 전체회의를 연다.

같은 '국회 ○○위원회'인데 한쪽만 라벨됨. '국회'가 단어 앞에 나온 142번 중 82번은 라벨이 빠져 있었다

EDA ① 원본 데이터 · AI Hub 웹데이터 기반 한국어 말뭉치

데이터를 살펴보니 이런 문제가 있었고, 이렇게 처리했다

문제	무슨 뜻인가	그래서 이렇게 했다
태그 체계가 다름	보통 NER은 사람·장소·날짜를 찾는데, 이 데이터는 직업·기관·인공물 같은 7종을 찾도록 라벨돼 있다	공개 NER 모델을 쓸 수 없어 직접 학습
꼬리말이 개체로 라벨	기사 끝 저작권 문구의 '저작권자'가 28.7만 번, 언론사 이름이 약 44만 번 개체로 라벨돼 있다. 그대로 두면 의미 없는 문구를 외워 점수만 부풀려진다 (아래 예)	이런 문장과 똑같은 문장(중복 7.4%)을 빼고 학습
위치가 없음	라벨이 '삼성전자=기관'처럼 단어만 있고 문장 몇 번째 글자인지는 없다. 같은 단어가 한 문장에 두 번 나오는 경우도 12.2%	문장에서 찾아 나올 때마다 위치를 붙임
극심한 불균형	직업·기관 두 태그가 82%, 신조어는 0.1%. 흔한 태그만 잘해도 전체 점수가 높게 나온다	태그별 점수와 태그 평균 점수도 같이 봄
규모가 너무 큼	검증용만 690만 문장이라 다 쓸 수 없다	분야 17개에서 고르게 뽑아 30만 → 120만

꼬리말 예 (표본 400파일에서 1,048번 반복) <저작권자 직업 © 뉴스1코리아 기관, 무단전재 및 재배포 금지>

EDA ② 개체 경계

개체의 74%는 띄어쓰기에서 끝나지 않는다

25.6%

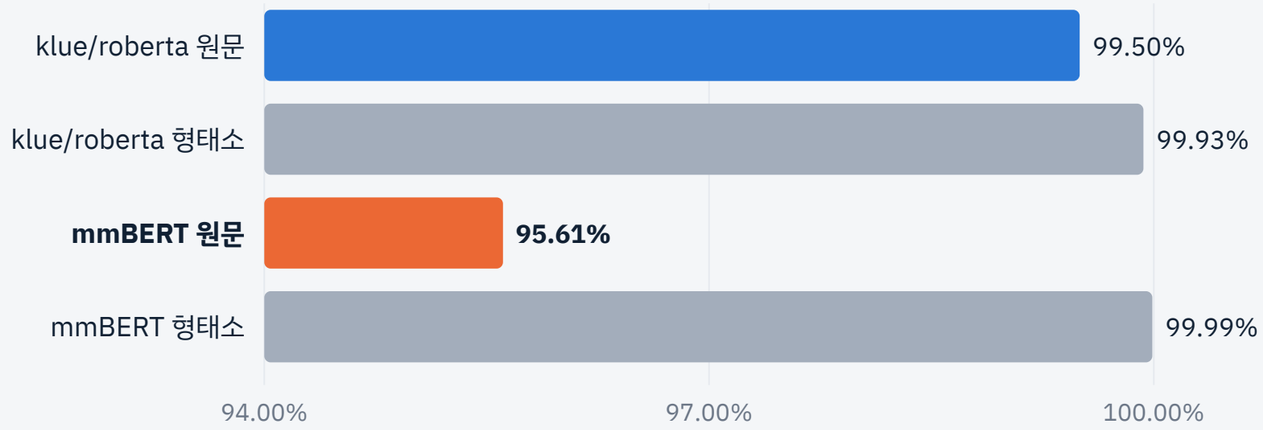
개체 양쪽이 띄어쓰기인 경우

44.2%

개체 바로 뒤에 조사 등 한글이 붙음
예) 광주교대<u>와</u>, 임차인<u>이</u>, 항공기<u>를</u>

결정 글자 위치로 정답을 만들고 토큰에 옮겨 학습, 채점도 글자 범위 정확 일치 · 경계 규칙을 배우는 **CRF** 헤드

토크나이저별 '개체 경계 = 토큰 경계' 비율



금융 Claude 표본 개체 22,718개로 측정. mmBERT는 형태소 분리 입력에서만 경계가 맞음 → **mmBERT만 형태소 입력** 사용

EDA ③ 라벨 일관성

1단계 점수를 막은 것은 모델이 아니라 라벨이었다

17.3%
자주 나오는 개체 문자열 중
문장마다 태그가 달라지는 비율

33.5%
자주 라벨되는 말이 나왔는데
라벨이 빠진 비율

15.9%
모델 6개가 모두 틀린 test 정답
(대부분 정답 쪽 문제)

같은 단어인데 문장마다 처리가 다르다 (원본 test 데이터)

문장	원본 라벨	이 단어 전체
검찰은 1심 결과에 불복하여 항소장을 제출했다.	기관	라벨 3번
검찰은 유치원 운영자 42명과 영양사 16명 등을 … 불구속 입건했다.	**라벨 없음**	빠짐 48번
청와대는 8일 스티븐 비건 … 특별대표가 ‘아직 평양에 있다’	**인공물 (기관이어야 함)**	인공물 161 · 기관 117 (전체)

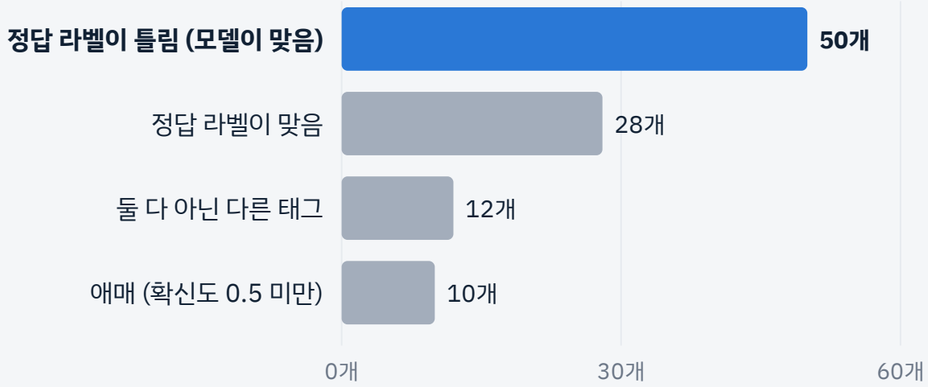
→ 2단계는 원본 라벨을 고쳐 쓰지 않고, 기준서로 일관된 라벨을 새로 만든다

EDA ③-2 AI 모델로 기존 라벨 검증

AI 모델로 확인해 보니, 우리 모델이 맞고 정답이 틀린 경우가 많았다

① 판정 전용 모델(Jev)에게 “누가 맞나” 묻기

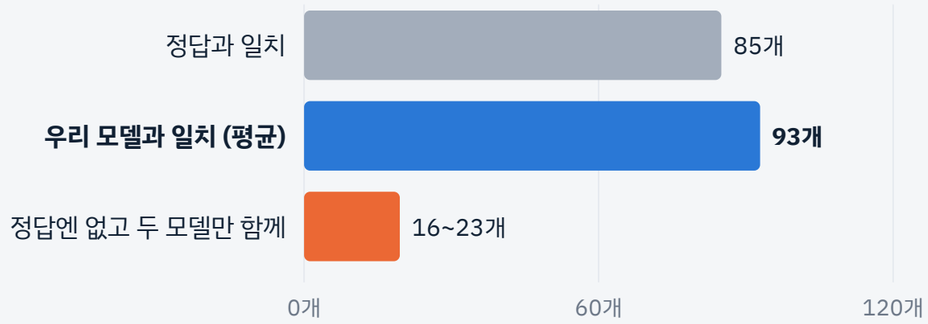
우리 모델 12개 중 10개 이상이 같은 답인데 정답과 다른 곳 2,890개 중 100개 (API 호출)



100곳 중 **50곳은 정답 라벨이 틀리고 모델이 맞았다**고 판정 (개체가 아님 18 · 범위 오류 12 · 태그 오류 12 · 라벨 누락 8)

② Opus가 단 개체는 정답보다 우리 모델과 더 겹쳤다

기존 정답이 있는 test 100문장(정답 146개)을 Claude Opus 5.5 API로 라벨링 → Opus가 단 403개 중



기획재정부 **Opus: 기관**가 20일 발간한 ‘월간 재정동향 5월호’에 따르면 …

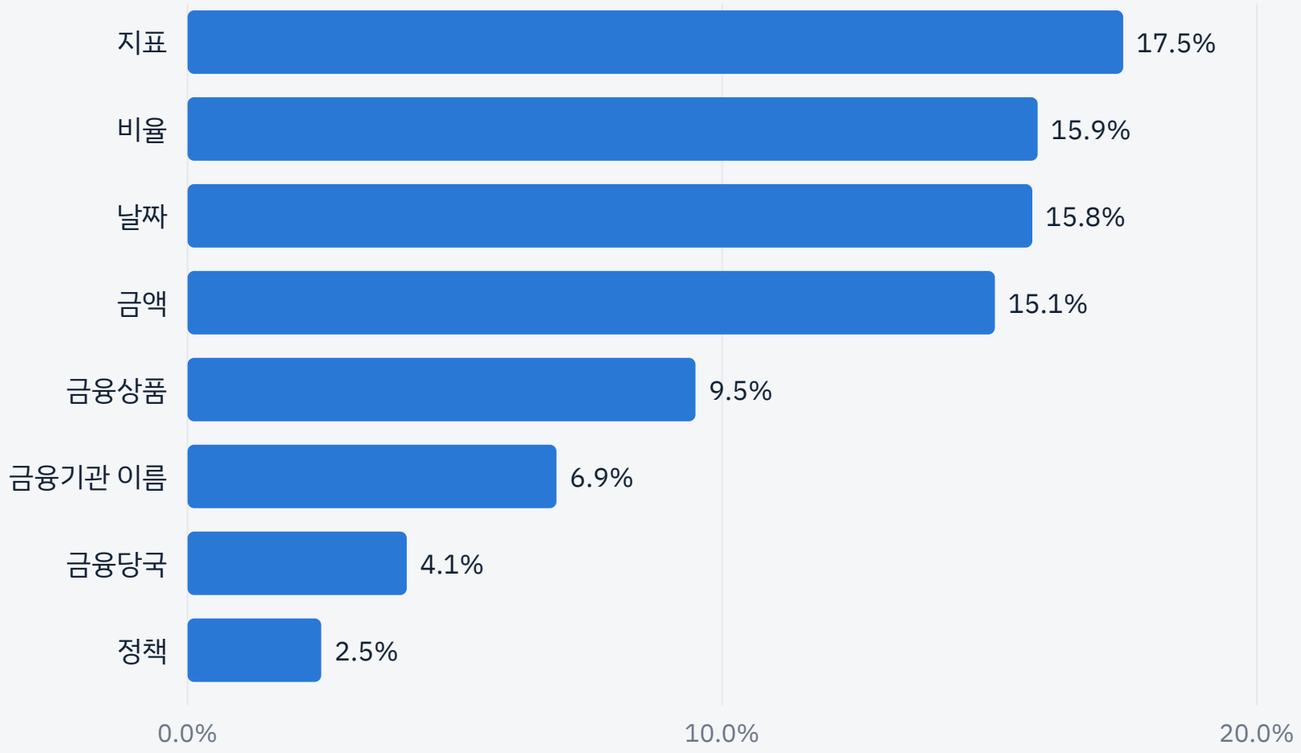
기존 정답: 라벨 없음 · Opus는 정답에 없는 개체를 272개 더 달아 넓게 다는 편

→ 기존 정답에 빠지거나 틀린 라벨이 있어, 우리 모델이 제대로 달아도 오답 처리되었다

EDA ④ 경제 기사 10만 문장

경제 기사의 핵심 정보는 원본 태그에 없었다

경제 문장 중 해당 표현이 나오는 비율



경제 카테고리 540만 문장 중 무작위 10만, 키워드·정규식 기반 근사

54.8%

금융기관 이름이 원본에서
기관(OG)으로 정확히 라벨된 비율

44.3%

원본 라벨이 하나도 없는 경제 문장

결정 금융 8태그를 새로 정의하고, 경제 문장 540만에서 라벨링 대상을 뽑는다

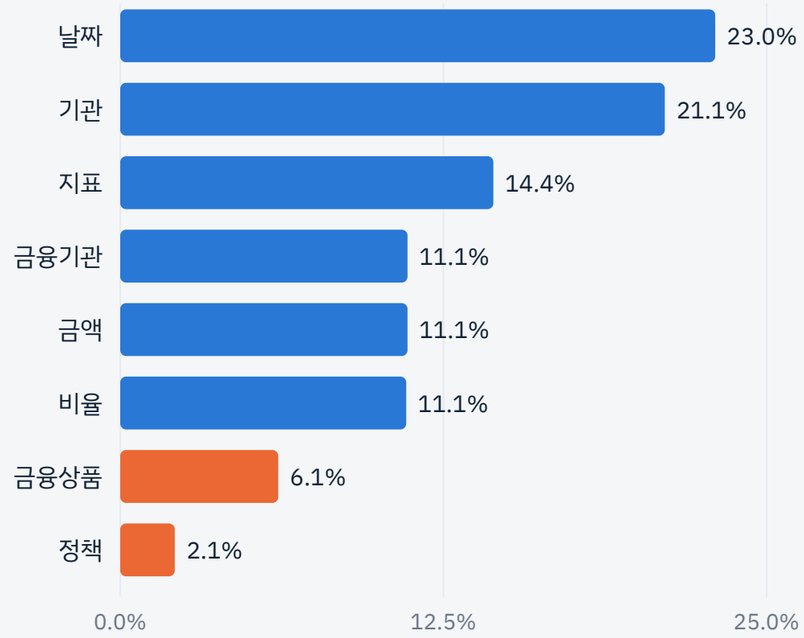
구현 전략 ① 금융 라벨 정의 (GUIDE v1.2)

금융 8태그와 경계 규칙

태그	뜻	예
금융기관 FIN_ORG	금융회사·금융당국	우리은행, 금감원, 한은
기관 ORG	그 밖의 기업·기관	삼성전자, 기재부
금융상품 FIN_PRODUCT	금융상품	ETF, 주택담보대출
금액 MONEY	금액	5000억원
비율 RATE	비율·금리 값	3.5%, 0.25%p
날짜 DATE	날짜·기간	지난해, 3분기
지표 INDICATOR	지표 이름	코스피, 영업이익, 환율
정책 POLICY	법·정책·세금·규제	DSR, 양도세

경계 규칙: 조사 빼기(우리은행은 → 우리은행) · 지표와 값 따로(기준금리 / 3.5%) · 수식어 빼기(약 5000억원) · '지난' 빼기 · 시각 빼기 · 사람 이름은 달지 않음

만든 학습 데이터의 태그 비율



학습 279,925문장 · 개체 629,644개 · 문장당 2.25개

구현 전략 ② LLM 라벨링

라벨링은 Opus 5.5에게 맡기고, 우리가 만든 기준서를 철저히 따르게 했다

1. **기준서 만들기** 팀이 직접 라벨링한 **40개 문장**을 바탕으로, LLM이 지켜야 할 규칙을 기준서(GUIDE)로 정리
2. **Opus 5.5가 라벨링** 5명 × 6만 문장, 각자 Claude 세션이 문장을 직접 읽고 판단 (정규식 자동 라벨 금지)
3. **시험 통과 후 시작** 정답이 있는 맞추기 10문장에서 F1 0.9 이상
4. **50문장씩 자동 검사** 문장에 없는 글자, 개체 겹침, 태그 오타, 빠진 문장 → 통과해야 저장
5. **기준서 개정** 판단이 갈린 항목을 정해 v1 → v1.2, 30만 전체 재적용으로 **8,058문장 수정**

기준서 규칙의 예

규칙	원문	라벨
조사 빼기	우리은행은	우리은행
‘지난’ 빼기	지난 9일	9일
시각 빼기	17일 오전 9시29분	17일
‘대’ 빼기	2%대	2%
지표와 값 따로	기준금리 3.5%	기준금리 3.5%
표현 통일	뉴욕증시	뉴욕증시 지표
애매하면 안 단다	대출·보험·상품 단독	달지 않음

구현 전략 ③ 평가 설계와 라벨 품질 확인

같은 조건으로 채점하고, Opus 라벨이 기준서를 잘 따랐는지 확인했다

나누기

학습 279,925 / 검증 10,040 / 테스트 10,035
기사 원본 파일 단위로 나눠 세트 간 겹침 0

채점

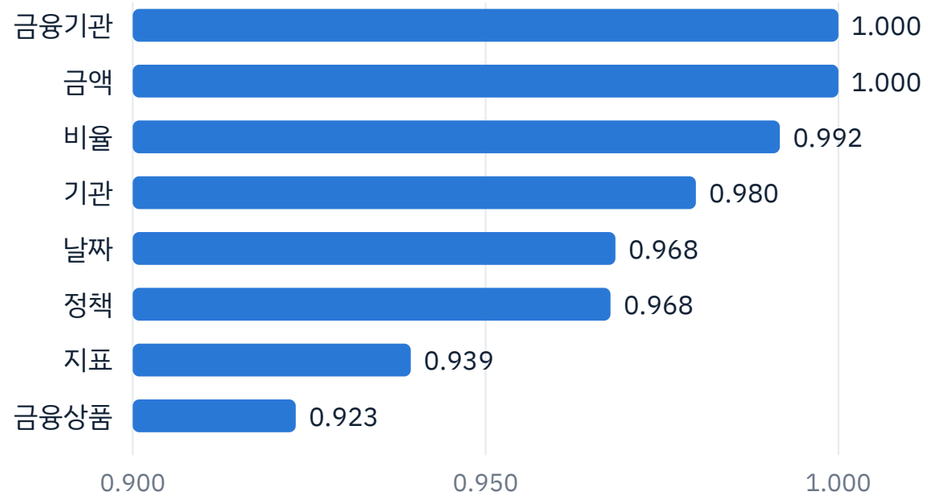
시작·끝·태그가 정답과 **정확히 같아야** 정답. 전체 F1 + 태그 평균 F1, 오답은 유형별로 기록. 설정은 검증 세트로만 정하고 **test는 마지막에 한 번**

Opus가 기준서를 얼마나 잘 따랐나

학습에 쓰지 않은 새 기사 350문장(네이버 경제 8분야 · 2020~2026년 · 34개 언론사)에
상위 모델 **Fable 5.1**에게 **같은 기준서**를 주고 따로 라벨링 → **Opus 5.5** 라벨과 비교

0.975

Opus–Fable 일치 F1
상위 모델과 97.5% 일치
(문장 완전 일치 325/350)



이 350문장은 학습 데이터와 겹치지 않아, 뒤에서 모델의 외부 점수(Fable 라벨 기준)로도 쓴다

데모

네이버 기사 위에 바로 개체를 표시하는 크롬 확장



모델 고르기

03(1위) · 12 KoELECTRA · ★앙상블(03+12+03s) · Claude API, 조사 자르기 후처리 포함

Claude와 비교

같은 기사를 Claude(기준서 v1.2)가 라벨링 → 일치도(F1)와 다르게 단 개체 목록. 한 번 받은 결과는 저장해 재사용

속도 (기사 1건, 실측)

GPU 서버 03 1~3초 · 앙상블 약 3초
노트북 CPU 03 8.7초

구현 전략 ④ 모델 탐색

다섯 가지 축으로 후보를 설계했다

축	무엇을 비교했나	왜
경제 도메인 사전학습	경제 문장 500만으로 '가린 단어 맞히기(MLM)' 추가 학습한 모델 vs 공개 모델	금융 어휘·표기(억원, %p, 코스피)를 미리 익히게
1단계 NER 이어받기	일반 뉴스 NER 500만 문장(7태그)을 먼저 배운 모델에서 출발	'개체 찾기' 능력이 옮겨 가는지
구조·크기	klue/roberta base·large, 최신 다국어 mmBERT(형태소 입력), 기준 모델 klue/bert · klue/roberta · KoELECTRA · mmBERT-small	한국어 기본기 vs 최신 구조, 크기 효과
출력층	CRF vs softmax	경계 규칙을 배우는 CRF의 효과
LLM 생성형	gpt-oss-20b + LoRA(경제 사전학습 → 금융 학습), 답을 '개체=태그' 글로 생성	거대 LLM이 더 나은지

공통 고정: 3에폭 · 배치 16 · 최대 256토큰 · 예열 10% · 시드 42 · 같은 채점기. 팀원 5명이 Colab에서 나눠 실행

구현 전략 ⑤ 1위 모델 (RUN 03)

경제 사전학습 RoBERTa-large + CRF



RoBERTa = BERT와 구조는 같고, 공부법만 바꿨다

트랜스포머 인코더가 문장 전체를 앞뒤로 동시에 보고, **셀프 어텐션**으로 각 토큰이 다른 토큰을 얼마나 참고할지 계산해 문맥에 맞는 의미를 만든다.

	BERT (2018)	RoBERTa (2019)	왜
구조	트랜스포머 인코더	같음	공부법만 비교
빈칸 위치	한 번 정하면 고정	**매번 새로**	같은 문장도 다양하게
다음 문장 맞히기	있음	**뺌**	효과 없음
데이터 · 배치	16GB · 256	**160GB · 8,000**	더 많이, 더 오래

원 논문(영어) 기준. klue/bert·klue/roberta는 같은 한국어 말뭉치로 학습 → 우리 실험 10(bert) 0.9253 = 11(roberta) 0.9253

klue/roberta	base	large (사용)
층 수 · 은닉 크기 · 헤드	12 · 768 · 12	**24 · 1024 · 16**
파라미터	약 1.1억	**약 3.4억**

우리가 더한 것

① 경제 기사 500만 문장으로 빈칸 맞히기를 한 번 더 (손실 6.38 → 1.07, 단 같은 크기 비교에선 큰 효과 없음 → 22장)
② 분류층 + CRF를 얹어 금융 8태그(BIO: 시작 B·중간 I·아님 O → 17라벨) 학습 → test F1 **0.926** (조사 자르기 후처리 후 **0.929**)

구현 전략 ⑥ CRF

CRF는 문장 전체에서 가장 말이 되는 태그 줄을 고른다

예시: 토큰별 점수(방출 점수, 설명용으로 가정한 값)

	B-FIN_ORG	I-FIN_ORG	O
미래에셋	2.0	0.1	**2.2**
증권	0.5	**3.0**	1.0

분류층만: 토큰별 최고점 → O, I-FIN_ORG ✕ **시작 없이 중간**

CRF: 방출 점수 + 전이 점수(가정: O→I −5, B→I +2, O→O +1)

O → I : 2.2 + 3.0 − 5 = 0.2

O → O : 2.2 + 1.0 + 1 = 4.2

B → I : 2.0 + 3.0 + 2 = 7.0 → '미래에셋증권' 한 덩어리 금융기관 ✓

비유

분류층만 = 학생들이 문제를 나눠 풀고 서로 답을 안 본 채 제출
CRF = 검토자가 전체 답안을 보고 앞뒤가 맞게 정리

두 점수와 계산

방출 점수: 이 토큰이 이 태그일 정도 (RoBERTa가 계산)
전이 점수: 태그 A 다음 B가 자연스러운 정도 (CRF가 데이터에서 학습)
예측은 **비터비**(최고 경로만 기억하며 전진), 학습은 정답 태그 줄 전체의 확률을 높임

+0.006

같은 roberta-large에서 test F1 (CRF 0.9258 vs 없음 0.9201)
1단계에서도 경계 오답 1,469 → 1,316

KoELECTRA: 같은 구조, 다른 공부법(가짜 단어 찾기)

공부법 비교

RoBERTa · 빈칸 맞히기: 나는 오늘 [MASK]에서 밥을 먹었다 → '식당' (가린 15%에서만 배움)

ELECTRA · 가짜 단어 찾기: 작은 생성 모델이 단어를 바꿔치기 → 판별 모델이 모든 단어를 원본/가짜로 판단

나는 오늘 학교 가짜에서 밥을 먹었다 (나머지는 원본)

모든 토큰에서 배움 → 같은 계산량으로 더 많이 배움. 토큰마다 하나씩 판단하는 연습이 NER과 비슷. 학습 뒤엔 판별 모델(discriminator)만 사용

	RoBERTa-large (03)	KoELECTRA-base (12)
구조	트랜스포머 인코더	트랜스포머 인코더
사전학습	빈칸 맞히기	가짜 단어 찾기
단어장	3.2만	3.5만
크기	약 3.4억	약 1.1억
test F1 (후처리 포함)	**0.9289**	0.9237
외부 350 F1 (후처리 포함)	0.9245	**0.9314**

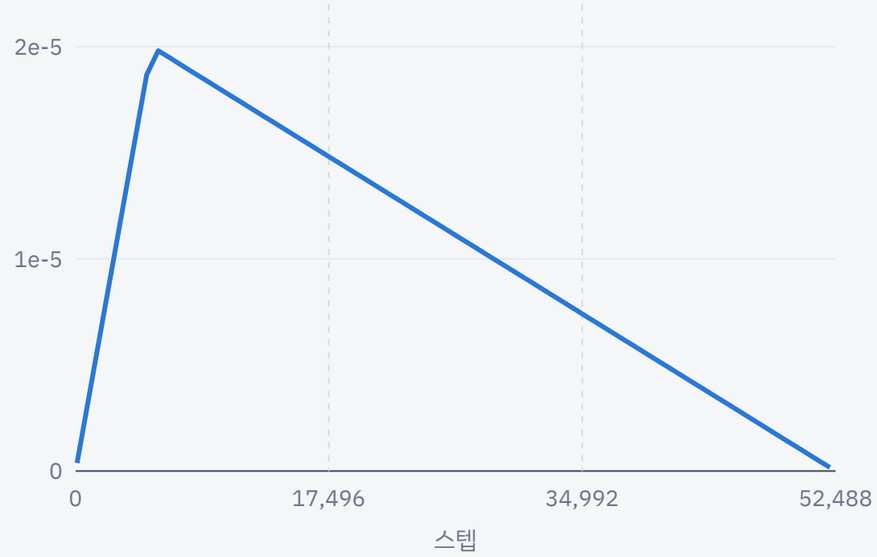
공부법이 달라 **틀리는 곳이 달라서** 앙상블에서 서로 보완 (결과 장)

구현 전략 ⑧ 학습 기법

안정적으로, 같은 조건으로 학습하기 위한 장치

기법	설정	이유
예열 + 선형 감소	처음 10% 동안 올리고 끝에 0으로	초반 흔들림 방지, 후반 미세 조정
학습률 따로 주기	본체 2e-5 · CRF 1e-3	새로 붙인 층은 빠르게, 본체는 조심스럽게
AdamW + 가중치 감쇠	0.01 (편향·정규화 층 제외)	과적합 억제
드롭아웃	0.1	과적합 억제
bf16 혼합 정밀도	16비트 계산	속도·메모리 절약
길이별 묶기	비슷한 길이 문장끼리 배치	패딩 낭비 감소
CRF 입력 정리	실제 글자 토큰만 모아 넣음	특수 토큰에 경계가 흔들리지 않게
체크포인트·이어 학습	2,000스텝마다 로컬 + 드라이브	Colab 끊김 대비, 같은 점수 재현 확인

RUN 03의 실제 학습률 (스텝별)

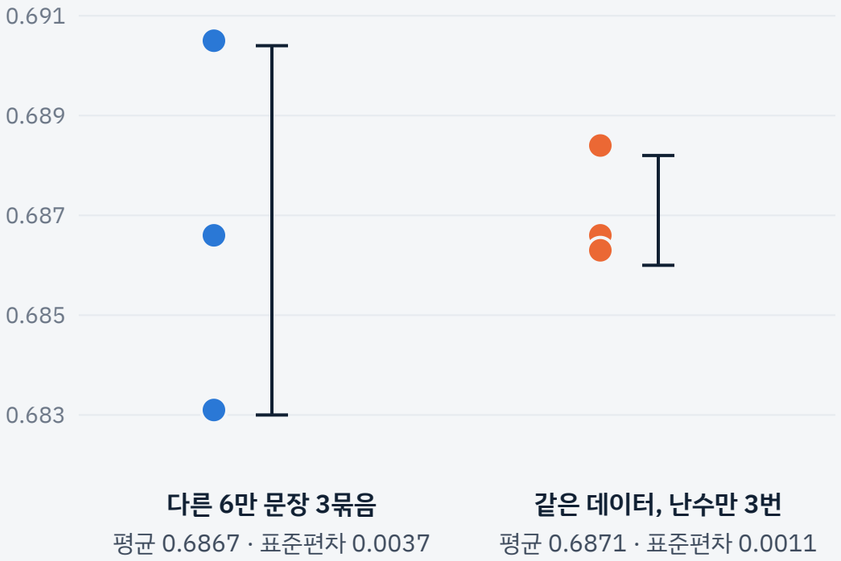


본체 학습률. 52,488스텝(3에폭) 동안 예열 후 0까지 선형 감소

결과 ① 첫 실험 (1단계, klue/roberta-base)

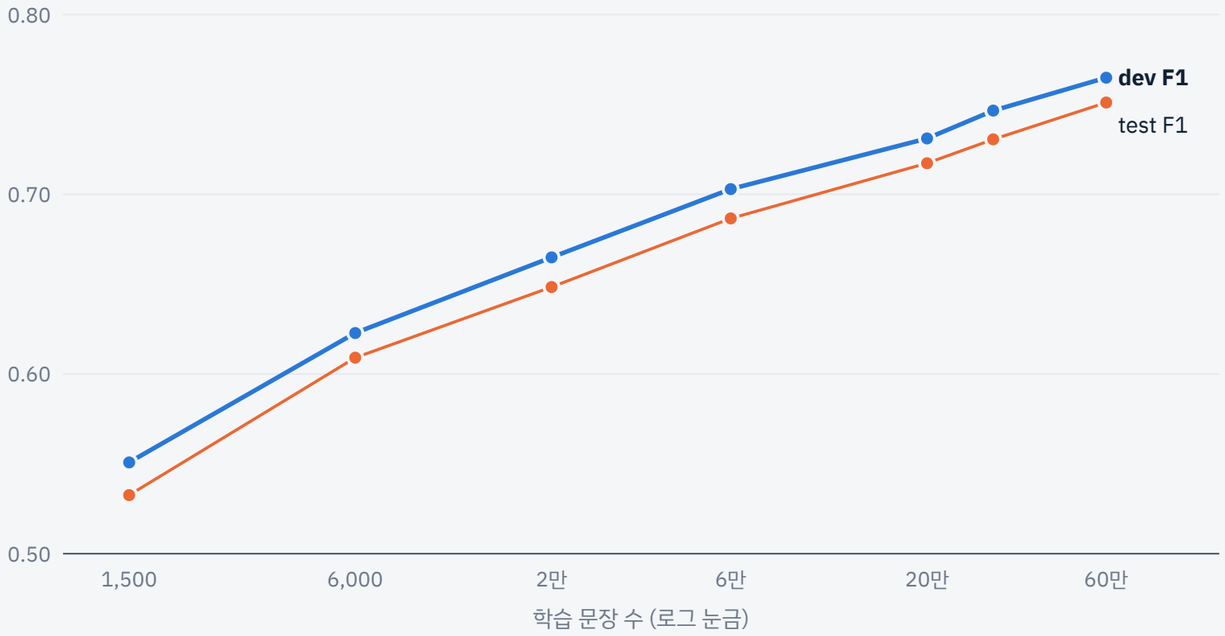
판정 기준을 먼저 정하고, 데이터 양이 한계임을 확인했다

학습 데이터를 바꾸면 점수가 얼마나 흔들리나 (6만 문장)



다른 6만 문장 3묶음으로 학습하면 test F1이 표준편차 0.0037만큼 흔들림 (같은 데이터에서 난수만 바꾸면 0.0011, 난수 = 처음 가중치·문장 순서) → **F1 차이 0.007(흔들림 ×2) 미만은 '차이 없음'**으로 결과 보기 전에 정함

학습 문장 수에 따른 F1

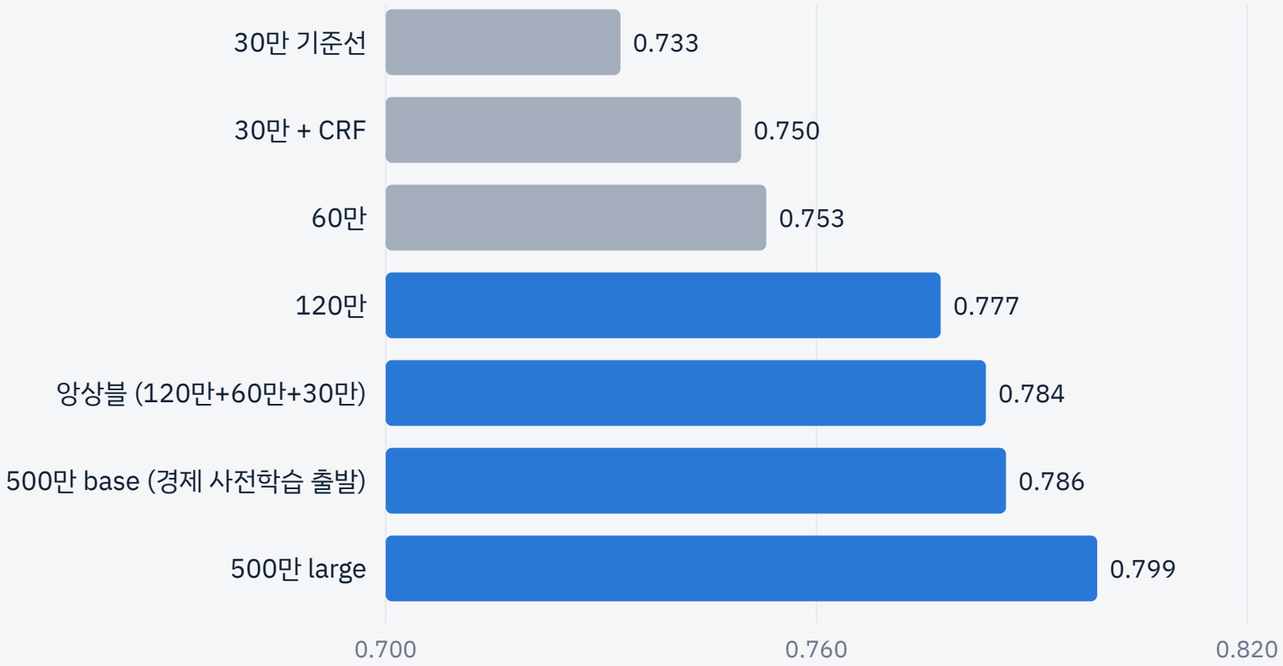


늘릴 때마다 흔들림 기준보다 훨씬 크게 오름(6만→20만 dev +2.8점) → **데이터가 적은 것이 한계**, 120만까지 늘림 (dev 0.788, 고친 정답 기준). 더 늘리면 개선 여지 있음

결과 ② 1단계 · 일반 뉴스 7태그

데이터 양은 효과가 있었고, 모델 바꾸기는 효과가 없었다

test F1 (고친 정답 기준)



효과 있음

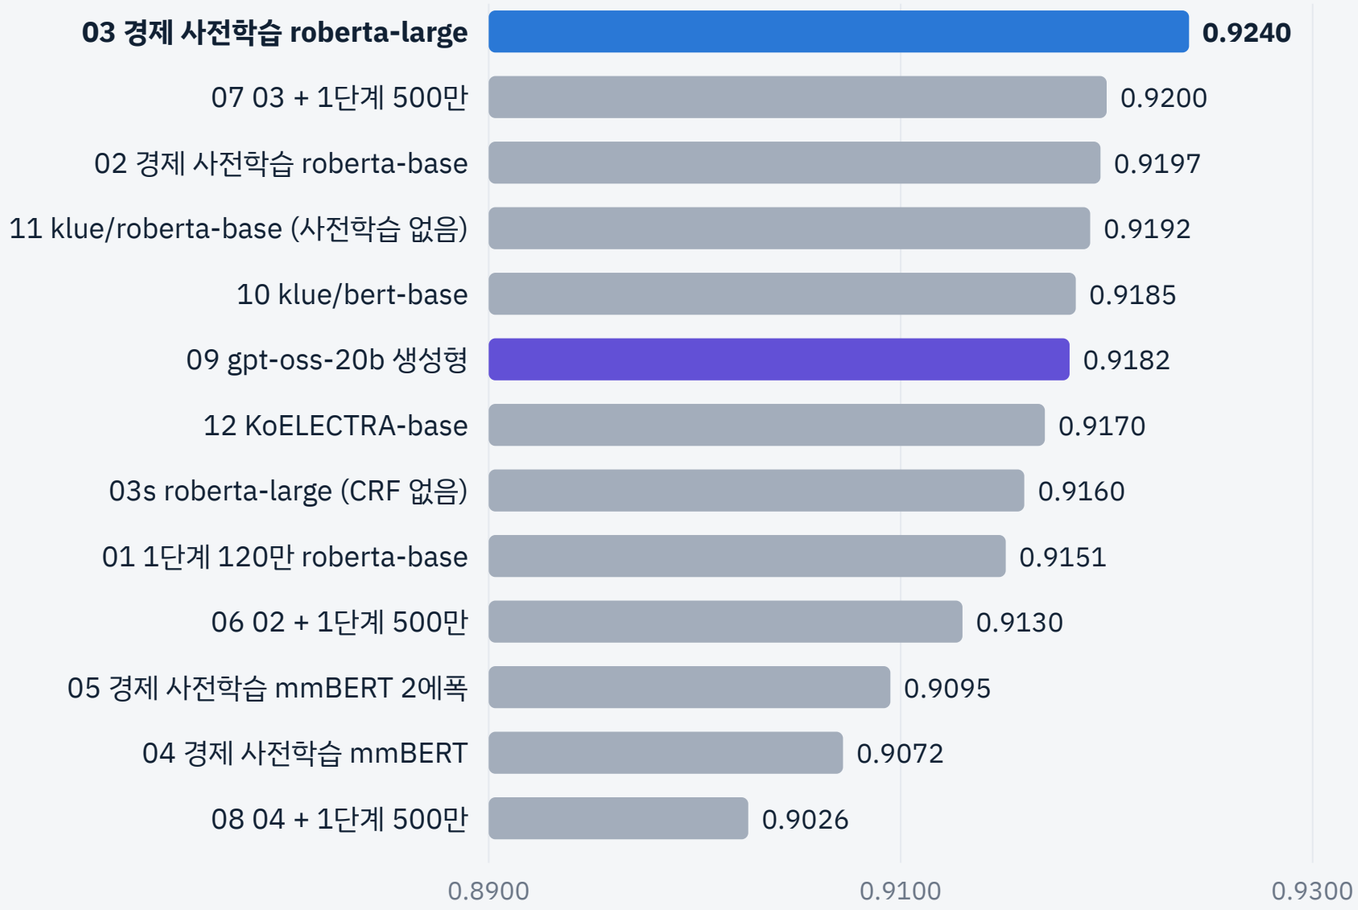
데이터 확대(60만 +1.8점, 120만 +2.2점) · CRF(+1.3점) · 서로 다른 모델 앙상블

효과 없음 / 손해

roberta-large · 학습률 2e-5·3e-5 · 5에폭 · KoELECTRA · 가중 손실 · 드문 태그 보강

1위는 경제 사전학습 roberta-large + CRF

test_2000 F1 (모든 모델 공통 2천 문장)



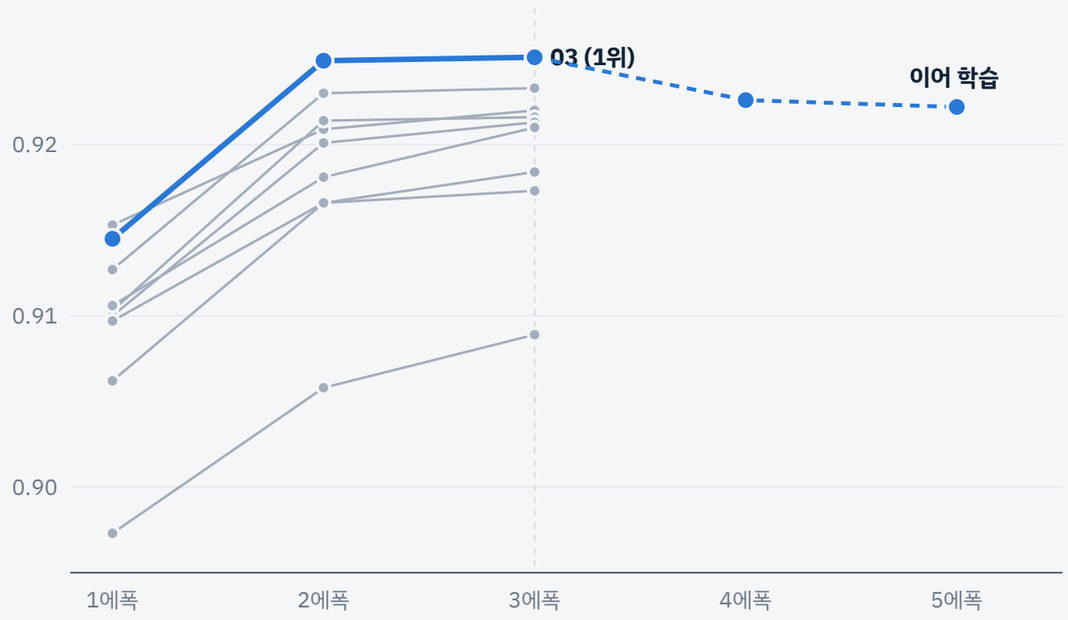
RUN	test 1만	외부 350
03	**0.9258**	**0.9211**
07	0.9233	0.9219
11	0.9221	0.9143
02	0.9214	0.9210
10	0.9220	0.9117
12	0.9206	0.9264
03s	0.9201	0.9160
01	0.9184	0.9054
06	0.9174	0.9080
05	0.9088	0.8998
04	0.9091	0.8957
08	0.9045	0.8936

외부 350 = 학습에 없던 기사 350문장(Fable 정답) · 후처리 전 점수
03을 5에폭까지 이어 학습(03c): test 0.9212 (3에폭보다 낮음)
13(mmBERT-small)은 다른 분할로 학습해 test 비교 제외

결과 ④ 학습 기록

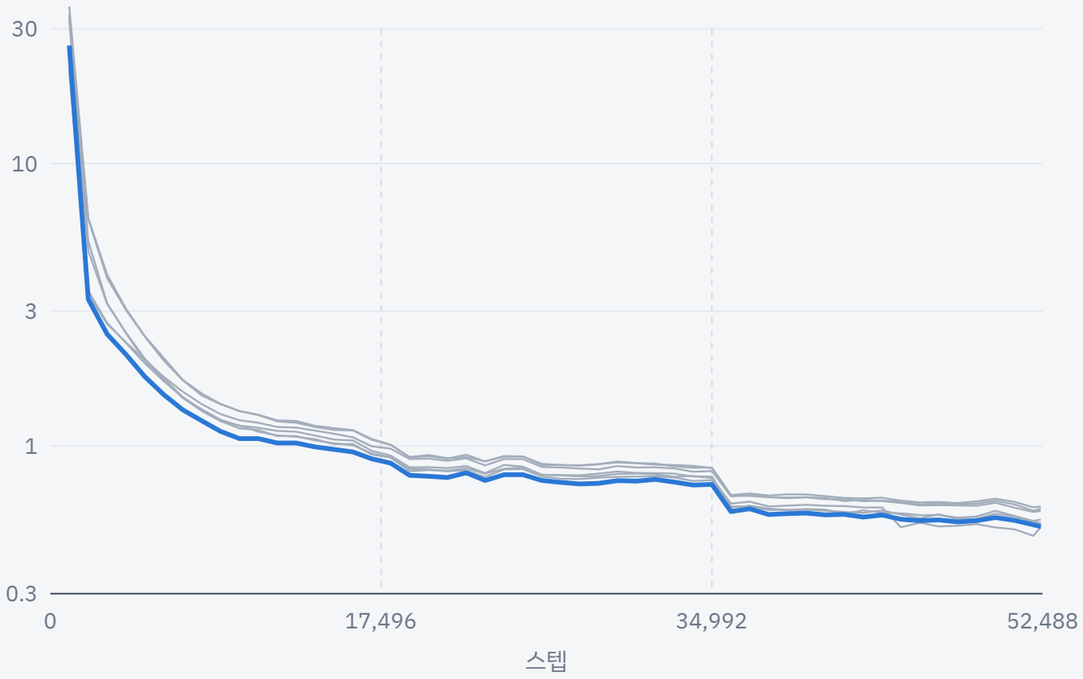
2에폭 이후 검증 점수는 멈췄고, 5에폭까지 늘려도 오르지 않았다

에폭별 검증(dev) F1



RUN 03 (1위) · 점선 = 4·5에폭 이어 학습　나머지 8개 (점에 마우스를 올리면 이름)

학습 손실 (스텝별, 로그 눈금)



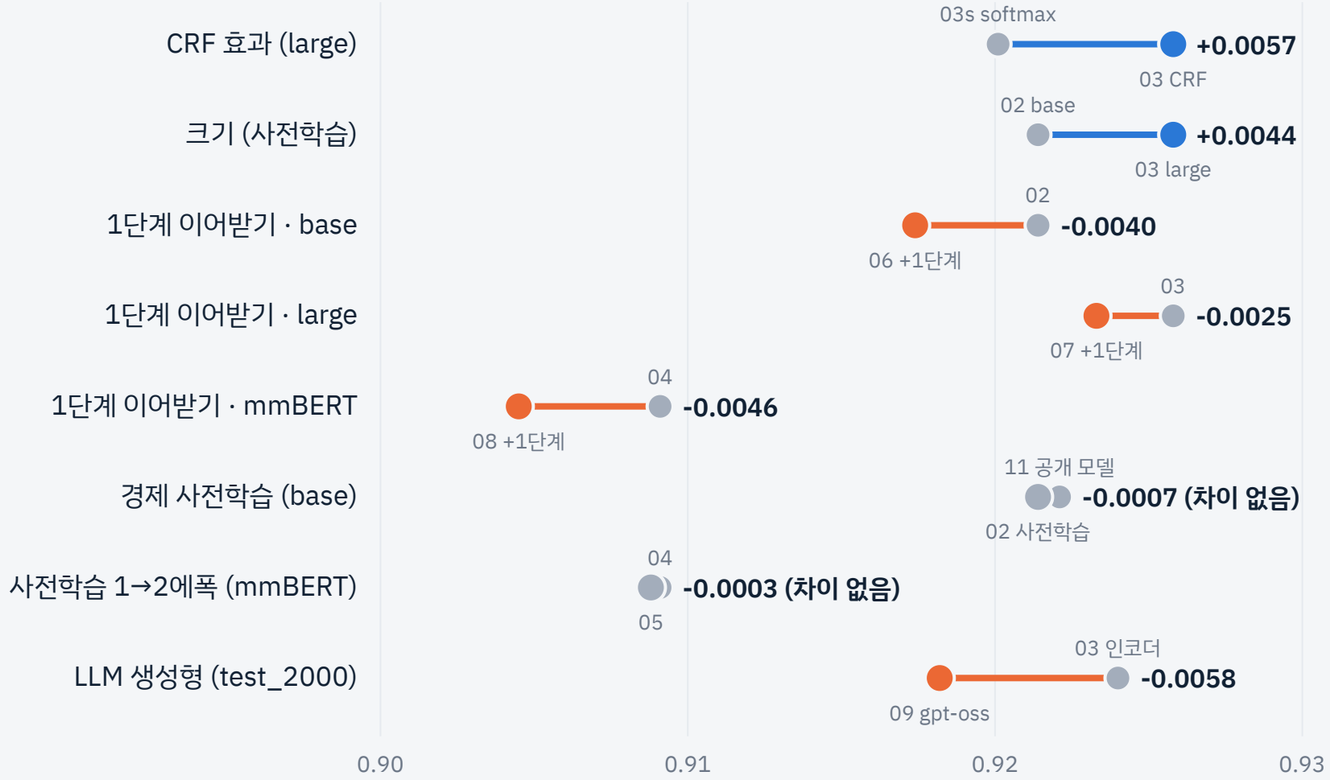
파란 선 = 1위 RUN 03. 세로 점선 = 에폭 경계. CRF 손실은 문장 단위라 값이 큼

5에폭 확인 1위 03을 이어서 2에폭 더 학습 → dev 0.9251 → 0.9226(4에폭) → 0.9222(5에폭). 더 학습해도 오르지 않고 조금 떨어짐 → **3에폭이 비용 대비 적절**했다

결과 ⑤ 시도별 결론

무엇이 도움이 됐고, 무엇이 손해였나

짝지은 비교: test F1 (gpt-oss 줄만 test_2000)



CRF +0.006 → 채택

큰 모델 +0.004. 1단계에선 효과 없었는데 라벨이 깨끗해지자 드러남

1단계 NER 이어받기 세 번 모두 손해. 7태그 습관이 8태그에 방해

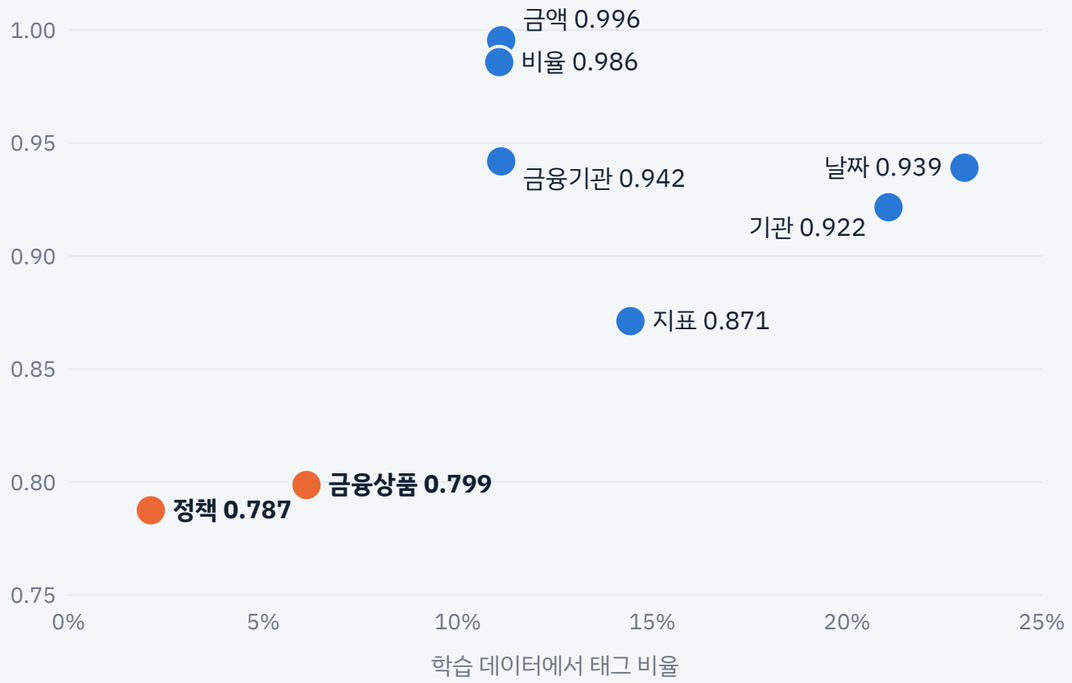
LLM 생성형 200억 3억 인코더보다 낮고, 2,500문장 채점에 23분

경제 사전학습 큰 효과 없음: 공개 모델 11과 02가 거의 같음(차이 0.0007 < 판정 기준 0.007), 2에폭 더 해도 같음(05≈04)

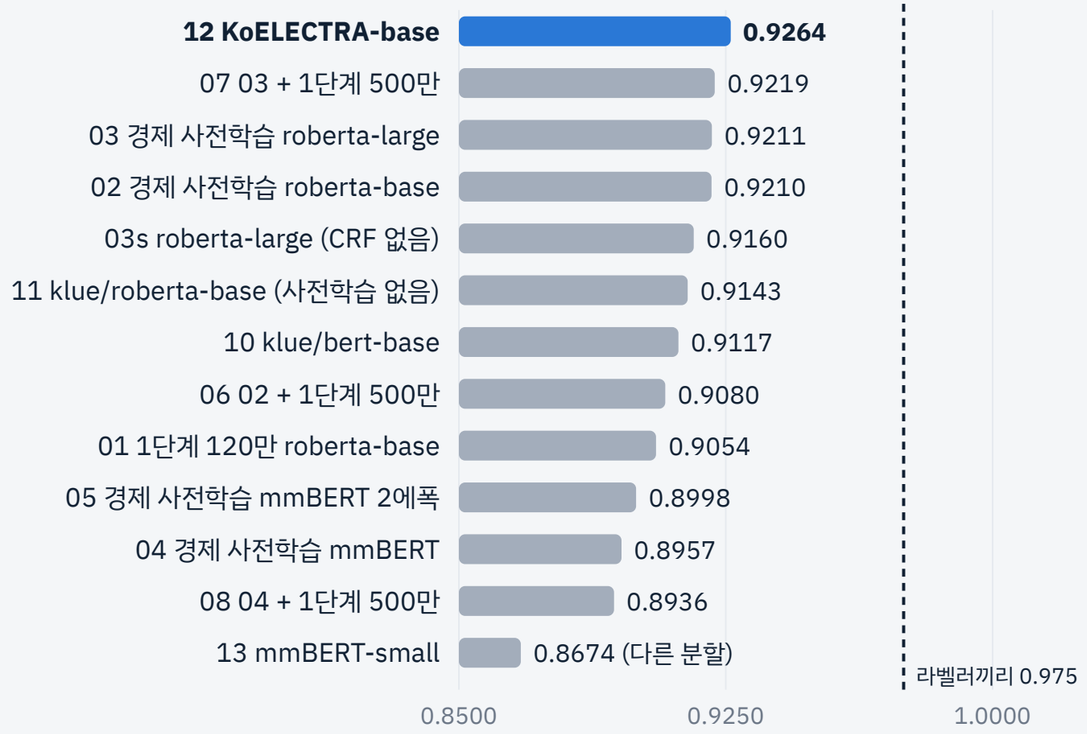
결과 ⑥ 태그별 · 외부 테스트

드문 태그가 가장 약했고, 처음 보는 기사에서도 0.9 안팎을 유지했다

RUN 03: 태그 비율(학습 데이터) vs test F1



외부 테스트 350문장 F1 (Fable 정답)

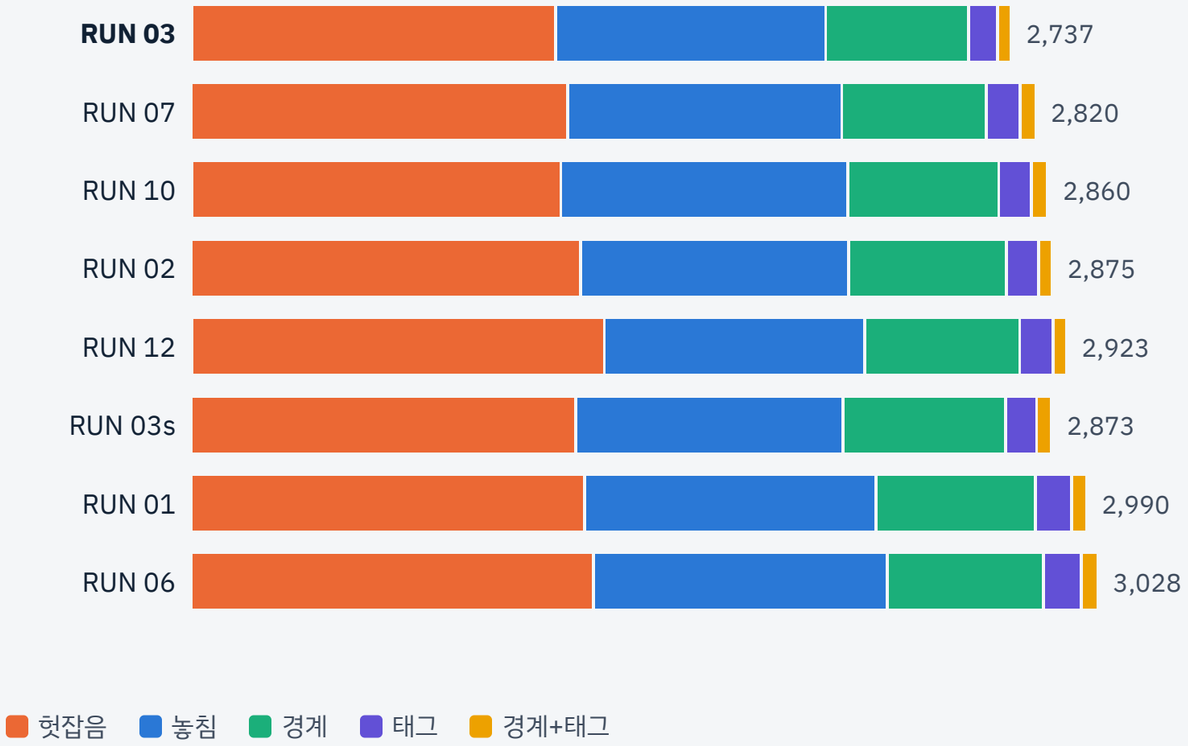


후처리 전 점수 · 13은 다른 분할로 학습

결과 ⑦ 오답 분석 → 후처리

모든 모델이 같은 곳에서 틀렸다

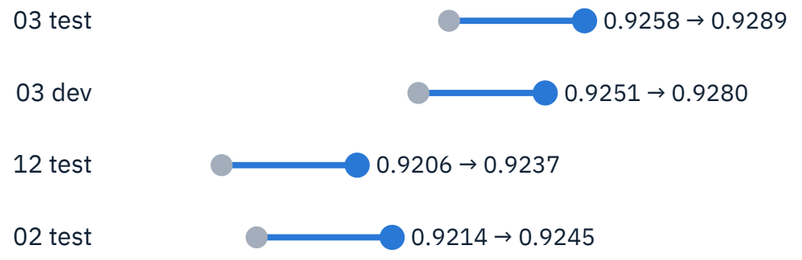
test 오답 유형 (정답 22,556개 기준)



토크나이저 한계

‘대출금리에’ → [대출금] [##리에] → 조사까지 잡힘 (test 개체의 0.61%)

후처리 시험: 조사 앞에서 자르기

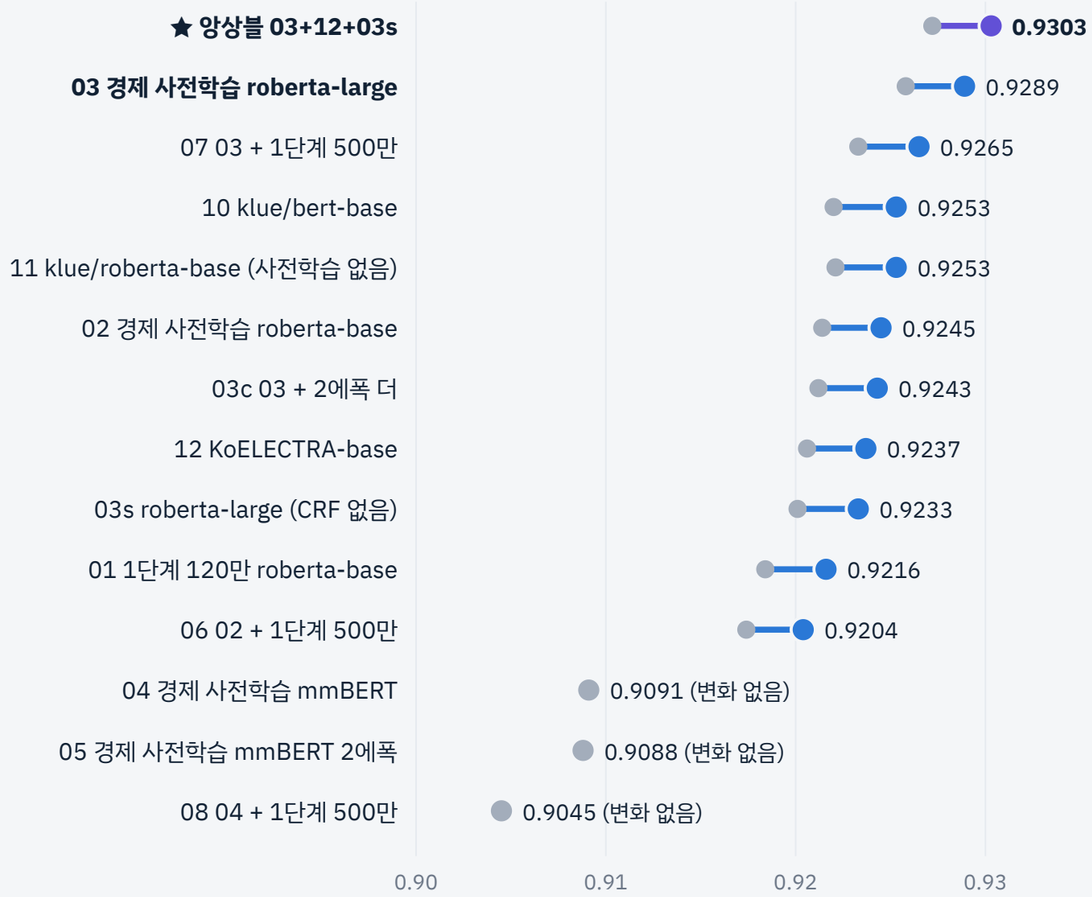


회색 = 원래 · 파랑 = 후처리 (규칙 조정 없이 적용)

많이 틀린 말: 주식·펀드·금리·이날·매출(라벨러마다 다르게 단 일반 단어) → 기준서 다음 개정 과제

조사 자르기 하나만 남겼고, 앙상블과 합쳐 test 0.930

test F1: 후처리 전 → 후 (모든 모델 같은 규칙)



규칙 4개를 검증(dev)으로만 시험 (RUN 03)

규칙	dev 변화	결정
조사 앞에서 자르기	**+0.0029**	**채택**
닫는 괄호 포함	0.0000	버림
앞 부호(+/−) 빼기	−0.0049	버림 (기준서는 부호 포함)
끝 '대' 빼기	+0.0001	버림

앙상블: 03 + 12 + 03s 다수결

3개 중 2개 이상이 같은 위치·태그로 단 개체만 남김. **조합은 dev 점수로 골랐다** (비슷한 상위 5개를 묶으면 효과 없음)

	dev	test	외부 350
03 단독	0.9280	0.9289	0.9245
앙상블	**0.9306**	**0.9303**	**0.9343**

둘 다 후처리 포함

한계와 다음 단계

남은 과제

정답도 LLM 라벨

사람 검수 없음 → 외부 테스트와 두 라벨러 일치도(0.975)로 보완

후처리 더 넓히기

조사 자르기·앙상블은 적용 완료. 조사가 아닌 꼬리말('장'·'째' 등)은 미시험

라벨이 흔들리는 곳

일반 단어(주식·펀드·금리), 금융기관/기관 구분, '오는'·'시장' 범위 → 기준서 v1.3

확장

데이터 더 늘리기(학습량 곡선상 여지 있음) · 공시·보도자료 같은 실제 금융 문서

정리

가장 큰 차이를 만든 것은 모델이 아니라 데이터를 분석하고 라벨을 일관되게 다시 만든 것

일반 뉴스 7태그 F1 0.78 → 금융 8태그 F1 0.929 (단일) · 0.930 (앙상블)

감사합니다